

中国科学技术大学

硕士学位论文



中国科学技术大学

基于智能手机的行为识别系统设计

作者姓名：郭乾
学科专业：电子与通信工程专业
导师姓名：刘斌 教授
完成时间：二〇一六年五月

University of Science and Technology of China
A dissertation for master's degree



**An Example of USTC Thesis
Template for Bachelor, Master
and Doctor**

| | |
|----------------|--------------------|
| Author: | Qiansun Zhao |
| Speciality: | Whatever |
| Supervisor: | Prof. Xueshen Qian |
| Finished Time: | June, 2099 |

中国科学技术大学学位论文原创性声明

本人声明所呈交的学位论文，是本人在导师指导下进行研究工作所取得的成果。除已特别加以标注和致谢的地方外，论文中不包含任何他人已经发表或撰写过的研究成果。与我一同工作的同志对本研究所做的贡献均已在论文中作了明确的说明。

作者签名：_____

签字日期：_____

中国科学技术大学学位论文授权使用声明

作为申请学位的条件之一，学位论文著作权拥有者授权中国科学技术大学拥有学位论文的部分使用权，即：学校有权按有关规定向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅，可以将学位论文编入《中国学位论文全文数据库》等有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。本人提交的电子文档的内容和纸质论文的内容相一致。

保密的学位论文在解密后也遵守此规定。

☐ 公开 ☐ 保密（_____ 年）

作者签名：_____

导师签名：_____

签字日期：_____

签字日期：_____

摘 要

本文是中国科学技术大学本硕博毕业论文模板示例文件。本模板由 ywg@USTC 创建，适用于撰写学士、硕士和博士学位论文，本模板由原来的本科模板和硕博模板整合优化而来。本示例文件除了介绍本模板的基础用法外，本文还是一个简要的学位论文写作指南。

关键词：中国科学技术大学 学位论文 \LaTeX 通用模板 学士 硕士 博士
测试 测试 测试 测试 测试

ABSTRACT

This is USTC thesis template for bachelor, master and doctor user's guide. The template is created by ywg@USTC and a derivative of USTC Bachelor and Master-PhD templates. Besides that the usage of the template, a brief guideline for writing thesis is also provided.

Key Words: University of Science and Technology of China (USTC), Thesis, Universal L^AT_EX Template, Bachelor, Master, PhD

目 录

| | |
|--------------------------------|-----|
| 摘要 | i |
| Abstract | iii |
| 第 1 章 绪论 | 1 |
| 1.1 研究背景与研究意义 | 1 |
| 1.2 国内外研究现状与发展趋势 | 3 |
| 1.2.1 基于智能手机的行为识别研究 | 4 |
| 1.2.2 降低行为识别过程中能耗的策略研究 | 6 |
| 1.3 研究内容与贡献 | 6 |
| 1.4 本文结构与安排 | 8 |
| 第 2 章 基于智能手机的行为识别研究概述 | 11 |
| 2.1 数据采集 | 11 |
| 2.1.1 智能手机内置传感器 | 11 |
| 2.1.2 智能手机数据采集模块 | 15 |
| 2.2 数据预处理 | 16 |
| 2.2.1 低通滤波 | 16 |
| 2.2.2 数据分段 | 17 |
| 2.3 特征提取与特征选择 | 17 |
| 2.3.1 特征提取 | 17 |
| 2.3.2 特征选择 | 19 |
| 2.4 分类算法 | 19 |
| 2.4.1 基础分类算法 | 20 |
| 2.4.2 提升分类算法 | 21 |
| 2.5 本章小结 | 22 |
| 第 3 章 基于智能手机的两层多策略行为识别框架 | 23 |
| 3.1 数据获取与处理 | 24 |
| 3.1.1 数据采集 | 24 |
| 3.1.2 特征提取 | 24 |
| 3.2 分类模型 | 26 |
| 3.2.1 分组模型 | 27 |
| 3.2.2 静态行为分类策略 | 28 |

目 录

| | |
|--------------------------|----|
| 3.2.3 动态行为分类策略 | 29 |
| 3.3 分类实验结果 | 30 |
| 3.3.1 数据采集实验以及参数设定 | 30 |
| 3.3.2 分类结果与分析 | 31 |
| 参考文献 | 35 |

图目录

| | | |
|-----|---------------------------------------|----|
| 2.1 | 行为识别基本框架流程图 | 11 |
| 2.2 | Android 全局和设备坐标系 | 13 |
| 2.3 | 陀螺仪结构图 | 14 |
| 2.4 | 决策树分类算法流程图 | 21 |
| 3.1 | 两层多策略的行为识别框架流程图 | 24 |
| 3.2 | The ACFs of three-dimensional signals | 26 |
| 3.3 | 行为之间的相似度 | 28 |
| 3.4 | 静态行为分类策略流程图 | 29 |
| 3.5 | 动态行为分类策略 | 30 |

表目录

| | | |
|-----|---------------------------------------|----|
| 2.1 | Android 系统平台下内置传感器分类表 | 12 |
| 3.1 | 本文用到的特征列表 | 24 |
| 3.2 | The result of activity grouping | 28 |
| 3.3 | The data set distribution | 30 |
| 3.4 | the results in the first layer | 31 |
| 3.5 | 静态行为分类策略的分类结果 | 31 |
| 3.6 | 动态行为分类策略的分类结果 | 32 |
| 3.7 | 本文框架的分类结果 | 32 |
| 3.8 | 文献的分类结果 | 33 |
| 3.9 | 文献的分类结果 | 33 |

第 1 章 绪论

1.1 研究背景与研究意义

近年来,随着微电子以及通信技术的不断进步与发展,各类小型化,具有感知、存储、通信和计算能力的设备开始普及与应用。伴随而来的是围绕着以人的需求为中心而展开的各类服务技术逐渐多样化和智能化。在各类服务应用中,一项重要的技术支撑——人体行为识别技术,越来越受到人们的关注。人体行为识别技术是借助于布置在人体周围的感知设备,采集并获取用户行为相关的数据,通过现有的有信号处理方法和模式识别技术,对用户当前行为做出识别和判断,从而为用户提供更加智能化的服务。基于行为识别的应用十分广泛,包括医疗健康、人机交互、智能家居、体育娱乐等诸多方面。在医疗健康方面,行为识别可以用于检测老年人跌倒或者精神病患者的异常行为举动等,以便于及时发现和救助。在人机交互方面,系统根据用户行为判读其需求及意图,及时进行系统控制调整,减少用户主动参与。在智能家居场景中,家庭管理系统根据用户当前行为判断用户需求,然后控制家居设备做出调整,使得服务更加智能化。另外,在体育和娱乐方面行为识别也有着广泛的应用,比如随身运动监测、体感游戏等。

人体行为识别技术从上世纪 90 年代开始发展^[1],近些年越来越收到研究者的关注。到目前为止,根据感知设备的不同,行为识别技术可以分为两大类,基于计算机视觉的行为识别和基于可穿戴传感器网络的行为识别。前者主要利用摄像头作为感知设备,通过处理拍摄得到的图像序列识别图像中人的行为^[2]。图像序列包含关于人体姿势与行为的大量细节信息且易于为人所理解,而且计算机视觉相关技术发展也日臻成熟与完善,因此较多的研究者开始借助计算机视觉技术,通过图像处理的方法提取有关人体行为的特征,进而实现人体行为识别。在这一研究领域也取得了较多的研究成果,获得了很高的识别准确率。但是这一技术是利用摄像头等设备采集图像信息,它有其自身固有的一定局限性。首先摄像头等设备通常被布设在一定区域范围内,所以无法长期获取用户的图像信息,不利于对用户长期进行行为监测与识别。其次是个人隐私问题,通过摄像头等设备拍摄的图像包含大量有关用户的细节信息,而用户通常不愿意过多地暴露个人信息,尤其是在智能家居等隐私敏感性场景下,这也给安全问题带来更大的挑战。最后是复杂性问题,图像处理一般都需要较为复杂的计算,这就给在进行行为识别的移动设备等硬件提出了更高的要求,因此需要配置较为复杂的系统,成本较高,对行为识别的应用与普及带来了负面的影响。相比较而言,基

于可穿戴传感器的行为识别技术^[3]则通过布设在人体身上的传感器采集人体行为有关的数据，一般是使用加速度传感器采集加速度数据，然后使用信号处理的方法和模式识别技术对人体行为进行识别与决策。因此基于可穿戴传感器的行为识别技术具有随时随地感知与识别并且隐私侵入小等优点，便于长期的行为监测。但是，基于可穿戴传感器就必须使用户在多个特定位置佩戴一定数量的传感器，必然造成一定的用户侵入性，使得用户体验较差，不利于行为识别技术的应用与普及。另外，多个布置在人体周围的传感器用户采集数据，也为传感器的能耗以及传感器与中心节点的数据通信问题带来了很大的挑战。

鉴于上述技术存在的问题，近几年一些人开始提出使用智能手机进行行为识别的方法。随着嵌入式技术的发展和硬件工艺水平的不断提高，传感器模块体积越来越小。各个硬件厂商为满足用户不断增加的需求，将越来越多的传感器设备集成到智能手机中。目前一般的智能手机通常都会集成有加速度传感器、磁场传感器、陀螺仪、温度传感器、GPS、压力传感器等硬件设备^[4]。除此以为，近些年智能手机的存储和计算能力也取得的很大的进步与发展。智能手机逐渐成为集感知、数据处理以及无线通讯为一体的智能化综合平台，拥有着强大的计算能力和数据通讯能力。因此，基于智能手机就可以实现从底层的数据采集到中间层的数据处理，再到上层的应用开发和服务提供以及云存储等功能。另一方面，随着智能手机的普及，现在几乎每个人都会配有一台智能手机，另外由于其与用户的密切关系，智能手机内置传感器可以更加方便且长时间地采集人体行为相关数据，而且没有额外的传感器负担和侵入性。除此之外基于智能手机的行为识别还拥有诸多其他的优点。首先，由于感知设备和数据处理设备都是集成在智能手机内部，因此我们不再需要考虑传感器节点与中心节点的通信问题，以及因为传感器能耗和不易充电引起的传感器的生命周期问题。。其次智能手机内部不但集成了基于可穿戴传感器的行为识别技术中经常用到的加速度传感器，而且还集成有其他运动传感器如磁场传感器、陀螺仪等可用于行为识别。最后，智能手机不断提升的存储和计算能力也很大程度上提高了识别的实时性。因此，基于智能手机的行为识别使用更加灵活方便，具有用户入侵性小，便于长期监测等优点，有利于行为识别技术的应用和普及。

虽然基于智能手机的行为识别相比对于可穿戴传感器，使用更加方便灵活且侵入性小，但是随之带来了一些其他的问题和挑战。首先，不同与可穿戴传感器，智能手机相对于人体的方向并非固定的，因此运动类型的传感器如加速度传感器等采集到的各轴向的传感器数据会随着方向的变化而变化，这给后续的数据处理以及行为识别造成很大的影响。其次，智能手机并不是像可穿戴传感器那样固定或绑定在人体上，它所处的位置也会不断发生变化，运动类型传感器采集的数据也会发生相应变化，尤其是对于动态下的行为，即使在相同行为下，传

传感器所采集数据也会具有很大的不同。这些也将会对最后的行为识别过程造成很大的影响。最后还有一个不能忽略的问题，相比于多个可穿戴传感器，智能手机在一段时间内仅能够采集人体单个位置的数据，而可穿戴传感器则可以通过部署在人体多个位置的传感器采集更加有效的数据，数据的不充分性也为后续的行为识别提出更大的挑战。以上是在如何提高识别结果上存在的问题与挑战，但是在移动环境这个特殊的系统条件下，能量消耗也是不得不考虑的问题。随着智能手机不断发展，移动设备上的应用也越来越广泛，人们使用智能手机也愈加频繁，而想要通过智能手机在后台对人体的行为进行长期监测，必须考虑如何降低在数据采集和行为识别过程中的能耗，从而减少因为行为识别对用户的影响，提高用户体验。

通过以上介绍可以发现，实现使用智能手机对人体行为进行识别与监测，首先是需要克服或者降低因为手机方向和位置变化对行为识别造成的影响，其次在保证一定的识别准确率的同时，努力降低在整个过程中的能量消耗，才可以使得这一技术为用户所接受，便于基于行为识别的各项应用的推广与普及。因此，本文首先针对基于智能手机的行为识别的研究，重点解决方向变化和位置变化问题，期望降低它们对行为识别造成的影响。其次，在保证一定准确率的同时，研究如何调整数据采集和识别过程中的一些变量，从而达到尽可能降低能耗的目的。

1.2 国内外研究现状与发展趋势

由于人体行为识别的应用背景极其广泛，并且随着通信技术、计算机技术以及模式识别等领域的不断发展与完善，利用感知设备获取人体环境信息对人体行为感知和识别的研究也越来越受到研究者的广泛关注。人体行为识别在上世纪 90 年代就已经被提出，而在刚开始人们对它的研究主要集中在计算机视觉领域，即通过基础设施中的摄像头等设备捕获关于人体行为的图像，进而通过图像处理方法提取特征对行为分类。一般来说，这种方法仅可应用于部分可拍摄到的区域^[5]，应用场景受限。此外还存在侵犯隐私，计算设备复杂，成本较高等缺点^[6]。近些年，随着微电子技术、集成电路、传感器技术等领域的不断进步，一些人开始关注于基于可穿戴传感器的行为识别方案^[7]。与基于计算机视觉的行为识别相比，使用可穿戴传感器较少依赖周围环境，同时具有低功耗、低成本、不侵犯隐私信息等优点。但是用户需要在身体的一些特定位置布设一些传感器，因此增加了用户的负担，存在用户侵入性，用户体验较差。另外基于可穿戴传感器的行为识别还需要考虑传感器与中心节点之间的通信以及传感器的能耗等问题。而在最近几年，智能手机逐渐走进人们的日常生活并且不断普及，由于

智能手机通常都会集成加速度传感器等感知设备，并且具备较强的存储和计算能力^[8]，因此研究者开始提出仅使用智能手机对人体行为进行监测和识别。基于智能手机的行为识别具有方便灵活的特点，并且对用户没有额外的负担，便于行为识别技术应用的推广。但是，由于智能手机所处环境的不可控性，如手机的方向与位置的变化等，这一项技术依然存在很多的问题和挑战。此外，随着智能设备不断进步，其存储和计算能力不断提升，而且在智能手机内部集成越来越多种类的传感器，这些也给基于智能手机的行为识别研究提供了更强大的平台，人们也开始提出很多在可穿戴传感器中难以实现的方法用于机遇智能手机的行为识别技术。另外一方面，由于移动设备的能量都是受限的，而通过智能手机采集人体行为相关数据并做行为识别又是需要长期执行的任务，因此部分研究者开始关注如何调整策略降低在识别过程中的能耗问题。本节的剩余部分将从基于智能手机行为识别的研究和降低识别过程中能耗的策略研究两个方面介绍目前国内外的研究状况。

1.2.1 基于智能手机的行为识别研究

智能手机内部集成的传感器包括很多种类型，按照其功能可以将其分为运动传感器和环境传感器。对于基于智能手机的行为识别研究可以根据使用传感器的种类不同分成两类。第一类是借鉴基于可穿戴传感器的行为识别中的方法，使用加速度传感器监测用户的运动信息，在使用智能手机采集数据时还可以使用磁场传感器、陀螺仪等获取其他的运动信息，辅助行为识别与决策。第二类是在使用运动传感器做行为识别的同时还研究了其他环境传感器所采集的关于用户的环境信息对行为识别的帮助。

对于智能手机中的运动传感器，Muhammad Shoaib 等人在^[9]中通过对比实验研究了除加速度传感器以外，陀螺仪和磁力计对行为识别的影响，实验分别对不同位置 and 不同行为分别做了对比实验，结果表明它们对不同位置的不同行为所起到的作用会有所不同，且区别较大，比如陀螺仪在区分上下楼和行走的过程中则具备较好效果，对其他行为区分度则不大。在一些研究中，继续沿用基于可穿戴传感器的行为识别方法，而将传感器替换为智能手机，进行人体行为识别^{[10][11]}。他们在实验室内通过将智能手机绑定在裤子口袋位置，并且规定了手机相对于人体的方向，即通过假定假定手机的位置和方向固定不变，重点研究三轴方向中特定方向上特征对行为识别的作用。但是这种假设过于严格与实际相差较大，不利于行为识别应用的推广。为此一些研究者重点研究了智能手机方向和位置变化对行为识别的影响，并提出了一些解决方案。

对于方向的变化问题，S. Thiemjarus 在^[12]中通过设置智能手机的方向，研究方向对加速度等传感器数据的影响。为降低手机方向变化问题对行为识别的

影响,一方面部分研究者通过使用方向独立的数据提取特征,M.B.Rasheed 等人在^[13]中使用传感器的三轴方向数据的信号模值向量最后的数据用于特征提取,从而避免方向变化带来的影响;另一方面则是利用旋转矩阵的方法作用于数据向量,进而减少方向变化带来的干扰。Anjum 等人和 S. Thiemjarus 等人分别在^{[14][15]}中提出使用旋转矩阵对传感器数据做变化,从而降低方向变化对行为识别的干扰。他们分别提出利用各轴向数据间的相关系数矩阵进行特征值分解以及基于投影的方法,计算得出旋转矩阵进而对数据进行旋转变换,减弱因方向变化对数据产生的干扰。虽然基于旋转矩阵可以一定程度上解决智能手机方向变化的问题,但是计算得到的旋转矩阵是手机坐标相对于地球坐标的角度,旋转以后的数据无法反映出用户身体相对于地球坐标系的变化,在一些行为的识别过程中丢失了方向信息。

对于位置的变化问题,一方面是使用位置独立的特征或分类方法,Changhai Wang 等人在^[16]中提出频域的特征受到位置变化的影响较小,使用频域特征时,在相同行为下,手机被放置在不同位置行为识别正确率较高。但是频域的特征只能适用于动态的行为,对于静止的行为则无能为力了。另一方面则是针对每个位置使用特定位置所采集的数据去训练不同的分类模型,但是在识别阶段这需要位置分类器首先识别其位置信息,然后使用不同的特定位置分类模型对行为进行识别分类。D. Kelly 等人在^[17]提出在行走状态下使用位置分类器检测智能手机在人体上的位置,但是这个位置分类器仅能够在人体行走状态下才能工作。而且在^[18]中,作者通过对比实验表明,位置独立的分类模型总体效果并没有优于所有位置的同一分类模型,这是因为位置分类器产生的错误分类对最终结果产生较大的影响。最后一些研究者则关注了单一位置采集数据造成数据集不能充分表征行为特征的问题。在^[19]中,作者研究表明多种类型的传感器数据可以补偿因为单一位置数据的不足。在^{[20][21]}等文献中,他们通过融合陀螺仪等其他智能手机中常见运动传感器数据进行行为识别,收到较好的效果。

除使用运动传感器以外,部分研究尝试使用智能手机内置的其他类型的情景感知传感器,通过检测用户周围的情景信息辅助行为检测。A.E.Halabi 等人在^[22]中研究通过结合使用手机内置压力传感器检测周围大气压力的变化用于区分上楼和下楼两种行为。R.D.Das 等人在^[23]中则利用 GPS 信息辅助行为识别的最终决策。在他们的研究中都一定程度上提高了识别准确率,但是由于这类传感器并没有集成在所有的智能手机中,所以使用这类传感器不利于行为识别技术的广泛应用。

1.2.2 降低行为识别过程中能耗的策略研究

作为移动端的设备,智能手机控制应用的能耗是十分有必要考虑的问题。对于降低行为识别过程中能耗问题,研究者主要针对于研究识别准确率与能耗之间的权衡策略。这部分的研究内容包括两个主要的问题,一是建立准确率和能耗模型并且权衡二者作出最佳策略选择,即通过研究准确率和能耗分别与哪些变化因素相关,以及他们之间的关系从而选择最佳策略;第二个问题是在识别过程中如何调整识别策略,从而在保证一定识别准确率的同时尽可能降低能耗。

对于准确率和能耗的影响因素,V.Q. Viet 等人和 Z.X. Yan 等人分别在^{[11][24]}考虑了传感器的采样率和用于分类的特征集对准确率和能耗的影响。但是他们都是通过采样率和特征集数值对的形式建立离散模型,研究他们对准确率和能耗的影响,并没有建立连续模型关系。在^[25]中,作者考虑了选择最佳传感器集合以及传感器采集数据的周期,在本文中重点研究了二者对准确率和能耗的影响。D. Gordon 等人则在^[26]同样考虑了传感器的选择,从而产生不同的特征集合,研究它们对准确率和能耗的影响,同时作者通过对比准确率,依照准确率的下降定义行为对特征的依赖程度,进而简历准确率与特征集的函数模型。N.H. Viet 等人在^[27]则时通过定义信息质量建立识别准确率与传感器的选择之间的函数模型,同时建立了各类消耗模型,从而通过求解目标函数的最优解问题做出最佳权衡决策。但是这些两篇文献都没有考虑准确率和能耗与采样率、采样周期等因素之间的关系模型。

通过研究识别准确率和能耗与一些变化因素之间的函数关系,可以为每一类行为权衡两个因变量选择最佳的识别策略,下一个问题就是如何在识别过程中做出动态的策略调整。在^{[11][24]}中时提出一种连续帧决策的方法,并引入了置信度的概念,进而在识别过程中根据前一个窗口时间内的识别结果决定当前时刻的策略。O. Yurur 等人在^[28]中则是行为识别与降低能耗在一起考虑,提出使用基于离散时间的非齐次隐半马尔科夫模型进行人体行为识别,同时提出使用约束马尔科夫决策过程和反馈机制去权衡识别准确率和能耗,从而动态地在决策过程中做出最佳策略选择。

1.3 研究内容与贡献

本文的主要研究内容包括以下三个方面:首先提出一种基于智能手机的两层多策略的行为识别方案框架,然后是研究降低行为识别过程中能耗的策略动态调整方法,最后在智能手机终端实现行为识别应用,验证方案框架与调整方法的实用性和有效性。

(1) 基于智能手机的两层多策略的行为识别方案框架

对于基于智能手机的行为识别过程中存在的手机位置和方向变化问题，本文首先提出使用一系列与数据自相关函数相关的特征以降低手机方向变化带来的影响。其次提出两层多策略的行为识别方案框架应对手机位置变化的问题。在该方案框架中，所有行为首先根据行为间的相似度被分为若干组，然后在第二层中，根据不同组的行为特点选择相应的最佳策略进行分类，并对动态行为引入位置分类器降低位置变化对识别结果的干扰。

该部分研究点的具体研究内容如下：

- a) 特征提取：首先通过智能手机内置的加速度传感器，磁力计和陀螺仪采集人体行为数据，然后对数据做预处理并通过加窗的方法进行分段，最后可以对窗口内的数据实例提取特征。在我们框架中采用了时域、频域和自相关函数相关的特征，其中频域特征可以有效降低位置敏感性，而在本文中又提出若干自相关函数的特征，与方向无关，可以有效降低方向变化对行为识别的干扰。
- b) 分组模型：在分类框架的第一层中，所有行为首先根据行为相似度分为若干组，如静态行为，慢速动态行为和快速动态行为等，然后以分组后的数据作为训练集训练分组模型，该分组模型用于框架的第一层将一个窗口内的行为实例分到某一个组。对于已经分组的行为，则可以在方案的第二层中根据不同组行为的不同特点采用不同的策略将组内的行为进一步分类，获取最终结果。
- c) 静态行为分类策略：对于静态行为，比如坐和站，很难通过运动类型传感器的数据分析二者之间的区别，因此在本文中提出通过识别静态行为转变过程中的过渡态行为，如站起和坐下，进而判断当前时刻的静止行为状态。
- d) 动态行为分类策略：对于动态行为，由于位置的变化对运动类型传感器所采集的运动数据模式造成很大的影响，因此本文针对动态行为引入位置分类器，对于动态行为针对不同位置训练特定位置的分类模型。对于动态行为引入位置分类器，一方面可以在运动状态下为位置识别提供较好的条件，提高位置识别准确率，另一方面又可以根据位置信息选择特定位置分类器，降低位置变化的干扰。

(2) 降低行为识别过程中能耗的策略动态调整方法

降低识别过程中能耗的基本思想就是通过调节一些影响因素，权衡识别准确率与能耗之间的关系，进而选择最佳的策略用于行为识别。在本文中，首先通过研究准确率和能耗与影响因素的关系，建立数学模型。然后针对每一类行为构

建目标函数权衡准确率与能耗的关系，通过求解最优化问题为每种行为选择最佳的识别策略。最后制定一套自适应的动态调整方法，使得最终的识别过程在保证一定准确率的基础之上可以降低能耗。

- a) 准确率与能耗模型：在本文中主要考虑的影响因素主要包括传感器的采样率和一个窗口时间的采样时间比例以及选择用于分类的特征集，即是否使用频域特征，是否使用自相关函数的特征。准确率和能耗与这些影响因素的关系则是首先建立数学模型，然后通过实验测量数据进行拟合或者计算模型中的参数，从而获得二者与上述影响因素变量之间的模型关系。
- b) 最优化问题：首先对于每一类行为都可以计算其相应准确率模型以及适用于所有行为的能耗模型，然后当前电量可以作为准确率和能耗的权衡系数，从而构建出目标函数，最后求解该目标函数的最优值而获得适用于当前电量以及该行为的最佳策略，包括应当选择的采样率，采样时间比例，是否使用频域以及自相关函数特征等。
- c) 动态调整方法：根据计算获得的每种行为的最佳策略，可以根据识别过程的实时结果作出动态调整。此部分的关键问题在于判定行为的转变，本文通过结合行为马尔科夫模型的转换概率和当前的行为识别结果，综合考虑判定行为转换结果，进而对识别策略作出动态调整，达到降低能耗的目的。

(3) 人体行为识别应用

本文最后将在运行 Android 系统的智能手机上实现一款人体行为识别应用，该应用中实现了我们的两层多策略的识别框架和降低能耗的最佳策略动态调整方法，并在实际的应用中统计识别结果以及能量消耗，从而验证本文方法的实用性与有效性。

1.4 本文结构与安排

本论文总共分为六章，各个章节的内容安排如下：

第一章是绪论，在本章中首先介绍了课题的研究背景与研究意义以及该研究方向的国内外研究现状，然后简要阐述了本文的主要研究内容和贡献，最后简要介绍本文的结构与安排。

第二章主要介绍了基于智能手机行为识别的相关背景与基础知识。首先简要介绍了行为识别的基本流程与框架以及需要解决的问题和存在的挑战，然后介绍了目前智能手机中常见的内置传感器以及其他可用于行为识别的感知设备，最后深入地介绍了行为识别，特别是基于智能手机的行为识别中所用到的特征集和分类模型。

第三章主要介绍了本文提出的两层多策略的行为识别方案框架。首先概述了该方案框架的整体结构和识别流程,然后深入地介绍了框架中的各部分包括数据采集和特征提取,分组模型,静态行为分类策略以及动态行为分类策略,最后给出了实验数据的识别结果以及与其他识别方法的对比实验结果。

第四章主要介绍了降低行为识别过程中能耗的动态策略调整方法。首先简要阐述了降低能耗的基本思想以及为每类行为计算最佳策略的基本方法,然后详细地介绍了该部分的各项内容,包括数学模型,最优化问题与求解以及动态的策略调整方法,最后给出使用该调整方法后的识别结果以及对比实验结果。

第五章主要介绍了本文中实现的人体行为识别应用,包括程序的主要结构框架,各部分的主要功能,主要界面以及操作方式等。

第六章首先对本文的主要内容作出了总结,然后对基于智能手机行为识别的相关研究做了展望。

第2章 基于智能手机的行为识别研究概述

人体行为识别就是通过感知设备获取关于人体行为的数据，然后通过信号处理和模式识别等技术手段对用户当前行为作出识别判断，其整体流程如图所示。行为识别的概念在上世纪八十年代就已经被提出，而在研究初期它仅仅局限在计算机视觉领域。研究者通过使用摄像头等作为感知设备获取关于人体的图像序列或视频片段，通过图像处理等技术手段提取特征并识别用户行为。随着微电子和集成电路等技术的发展，开始出现一些小型化，功能强大的传感器，一些研究者开始关注基于可穿戴传感器的行为识别技术。基于可穿戴传感器的行为识别主要使用加速度传感器采集人体的行为数据，然后提取时域和频域等特征进而识别用户行为。



图 2.1 行为识别基本框架流程图

近些年，随着智能手机的不断发展，其内部集成了越来越多的传感器，不仅包括在基于可穿戴传感器的行为识别中使用最多的加速度传感器，还包含有磁场传感器，陀螺仪等运动类型传感器，此外还有光照传感器，压力传感器，GPS 等环境信息感知设备，可以获取充足的关于用户行为和环境信息。另一方面，智能手机的存储和计算能力也在不断提高与发展，其功能不断拓展与增强，这些就为基于智能手机进行行为识别提供了良好的硬件基础。伴随着智能手机的普及与应用，研究者也开始将重点关注到基于智能手机的行为识别技术。

本章首先介绍智能手机内置的主要传感器以及其他感知设备，然后介绍在行为识别过程中必要的的数据预处理步骤以及常用的特征提取和特征选择方法，最后详细介绍部分可以用于智能手机行为识别的分类模型和算法。

2.1 数据采集

2.1.1 智能手机内置传感器

对于智能手机的内置传感器的介绍，本文以 Android 操作系统为例。Android 操作系统是一种基于 Linux 的自由及开放源码的操作系统，主要用于移动设备，

有 Google 公司和开放手机联盟领导开发。之所以选择 Android 系统为例介绍,一方面是因为 Android 是一款开源且成熟的移动端操作系统,另一方面它也是目前市场占有率最大的手机操作系统,因此更具有代表性。对于传感器的集成以及为应用提供的传感器数据服务,其他操作系统也都十分类似,本节只是不是一般性地以 Android 系统为例介绍智能手机中的内置传感器。

Android 系统平台支持的传感器类型很广泛,可以从功能和实现方式两个维度对其分类。一方面按照功能的不同,传感器可以分为运动类型传感器,环境传感器和方位传感器三类。运动类型传感器主要用于测量三轴向的加速度和角速度等,通常用于监测设备的移动,比如倾斜、震动、旋转或者摇摆等,主要包括加速度传感器、重力传感器、陀螺仪和旋转矢量传感器等。这一类型传感器在大部分智能手机内部都有集成,而且运动类型的数据也可以较好地用于人体行为识别。环境传感器则适用于测量各类环境信息参数,例如外界环境的温度、大气压强、光照强度和空气湿度等,主要包括温度传感器,气压传感器,湿度传感器等。这一类型传感器在部分智能手机内有集成,可以检测人体周围环境信息,辅助人体行为识别,但是没有普适性。方位传感器主要用于测量设备的方向,主要包括磁场传感器和方向传感器,此外一般智能手机都集成了近距离创拿起,可以用于检测设备表面与物体的距离。

另一方面按照实现方式的不同,传感器可以分为基于硬件和基于软件两类。基于硬件的传感器是集成在移动终端设备的物理实体。它们获得数据是通过直接测量特定的环境信息,比如加速度传感器,陀螺仪等。软件传感器是通过模拟硬件传感器,而并非真实的物理设备,它们是通过整合一个或多个硬件传感器信息相应数据,并通过一些融合方法计算获得相应模拟传感器的数据,因此也被称为虚拟传感器或者人工传感器,例如重力传感器,方向传感器等。Android 平台所支持的传感器总结如下表。

表 2.1 Android 系统平台下内置传感器分类表

| 分类 | 基于硬件的传感器 | 基于软件的传感器 |
|-------|---------------|----------------|
| 运动传感器 | 加速度传感器, 陀螺仪 | 线性加速度, 旋转矢量传感器 |
| 环境传感器 | 光照传感器, 气压传感器等 | |
| 方位传感器 | 磁场传感器, 近距离传感器 | 方向传感器, 重力传感器 |

下面本文详细介绍智能手机中常用于行为识别的传感器, 包括加速度传感器, 陀螺仪和磁场传感器。

- 加速度传感器

在 Android 系统平台下, 存在加速度和线性加速度两类测量设备加速度, 前

者是基于硬件的传感器，又开发商生产直接集成在智能手机内部，产生原始的加速度数据，该数据包含重力加速度的影响。而后者则是基于软件的传感器，它是有加速度数据和其他类型传感器的数据融合后计算而得到的加速度信息，排除了重力加速度的影响。二者都会提供 x, y, z 三轴方向的加速度数据，其中加速度数据不仅提供加速度的大小 (以 m/s^2 为单位)，还提供了加速度的方向。对于每个轴向，加速度存在正值和负值分别表示两个相反方向的加速度。三个轴向的定义如图所示。




图 2.2 Android 全局和设备坐标系

运动和方向传感器都是采集的矢量数据，数据的方向通常可以定义在直角坐标系中。Android 系统平台定义了两个直角坐标系用以表征设备方向的相对变化。两个坐标系包括全局坐标系 x_E, y_E, z_E 以及设备坐标系 x, y, z ，其相对关系如图。图中表示了智能手机略微倾斜地放置在地球赤道上方时方向相对关系。在全局坐标系中 y_E 指向磁场北极，即接近正北方， x_E 平行于地球表面，与 y_E 垂直， z_E 指向正上方，即远离地心的方向。在设备坐标系中， x 轴为水平方向，向右为正， y 轴为垂直方向，向上为正， z 轴为垂直于屏幕方向，屏幕正前方为正。几乎所有的三轴向的传感器都符合该坐标系包括下面会介绍的陀螺仪和磁场传感器，其所采集的数据均为全局坐标系中相应物理量在设备坐标系中三轴向的分解。

加速度数据可以很好地表征不同行为的特点，加速度传感器在行为识别中

也是应用最为广泛。基于可穿戴传感器的行为识别研究中,基于所有文献都是基于的加速度数据,而在智能手机中,加速度传感器集成也十分广泛,因此本文中它被选择为用于研究行为识别的传感器之一。

- 陀螺仪

陀螺仪是在设备发生旋转时,通过测量科氏 (Coriolis) 力测量设备在三个轴向上的角速度或旋转速度。所谓科氏力是指使得自由旋转物体从旋转参考系中看起来发生偏移的力。陀螺仪只能测量角速度,而不能直接测量旋转角度。但是可以通过陀螺仪的测量值在时间上的积分计算设备的旋转角度。陀螺仪的输出时绕设备坐标系的 x, y, z 三个轴向的旋转角速度值,单位为 rad/s 如果坐标轴指向你自己,逆时针旋转则为正值,反之为负值。




图 2.3 陀螺仪结构图

陀螺仪可以检测设备的旋转角速度,而在行为识别中,大部分的动态行为都是周期性行为,设备也会发生周期性旋转,所以通过处理陀螺仪数据可以很好地提取表征动态行为的特征,很好地辅助与行为识别。

- 磁场传感器

不同生产厂商的磁场传感器实现方式会有所不同。它们的实现方式主要可以分为基于霍尔效应、磁阻材料和洛伦兹力三种。其中霍尔效应传感器占据了最大的市场份额,在电流通过导线时,存在的磁场会使得导线两端的电子密度不同,从而形成正比于磁感应强度的电势差,通过电势差即可以计算出磁感应强度。磁场传感器也会以 x, y, z 三个轴向输出磁感应强度,因为集成的传感器是在每个方向上都有一个传感器。输出数据以微特斯拉为单位。

磁场传感器的输出可以很好地判断设备方向的变化。在行为识别中,当行为发生转变时,磁场传感器的输出也会起到很好的辅助作用。

2.1.2 智能手机数据采集模块

基于可穿戴传感器的行为识别中数据采集都是传感器将采集数据通过近距离通信的方式传送至中心节点，而基于智能手机的行为识别，其传感器和数据处理中心都是集成在手机内部，因此我们需要智能手机操作系统提供的编程接口，提取手机内置传感器的采集数据。Android 系统提供了一系列的应用编程接口 (Application Program Interface, API)，方便获取传感器的数据。有关传感器的操作都有 SensorManager 负责统一管理。

(1) 基本 API

SensorManager 是 Android 为便于应用访问传感器数据提供的系统服务。通过 SensorManager 一方面可以获取手机内置的传感器对象，用 Sensor 类表示设备种的传感器。另一方面通过 SensorManager 可以允许应用注册或注销传感器相关事件，并在注册成功后可以接受传感器数据。传感器事件可以通过注册的监听器 SensorEventListener 监听。注册传感器事件以获取传感器数据，需要提供对于的 Sensor 对象，SensorEventListener 对象和数据采集的采样时间间隔等。注册成功以后即可以通过定义的 SensorEventListener 中的回调方法获取传感器数据。

(2) 传感器采样率

在注册监听器时，通过指定监听器的采样间隔决定数据的采样率。在 Android 系统中，提供有四个常量表示采样间隔：SENSOR_DELAY_FASTEST (0ms, 硬件传感器决定采样率), SENSOR_DELAY_GAME (20ms, 50Hz), SENSOR_DELAY_UI (67ms, 15Hz), SENSOR_DELAY_NORMAL (200ms, 5Hz)。同样也可以通过指定其他的事件间隔，即指定采样率注册事件监听器以获取相应传感器数据。

(3) 传感器数据

Android 系统中传感器的数据是以一个 SensorEvent 数据结构表示，并由传感器传递至应用定义在监听器 SensorEventListener 中的回调方法中，从而将传感器数据传回到应用中。SensorEvent 包含以下属性用以保存数据：

- SensorEvent.accuracy: 表示传感器当前采集数据的精度
- SensorEvent.sensor: 表示采集该数据的传感器
- SensorEvent.timestamp: 表示采集到该数据的时间
- SensorEvent.values: 表示传感器的数据，以数组的形式保存三轴向的数据

2.2 数据预处理

首先,虽然智能手机不断发展,其内置传感器也在一直改进,但是传感器采集数据依然存在着许多噪声干扰,需要对数据做平滑和均衡处理。其次,传感器采集的关于人体行为的数据是一个连续数据流,想要通过数据流识别人体当前的行为,必然需要将其分割成一个个的数据实例,才可以对其提取特征并进一步做分类处理。因此本小节将从低通滤波和数据分段两部分介绍数据预处理的基本内容

2.2.1 低通滤波

对数据的平滑和均衡处理,主要是通过低通滤波的处理,有效减少数据中的高频噪声干扰。在移动终端这个条件下,通常会采用较为滤波方法,常见的简单滤波方法有加权平滑滤波和滑动平均滤波等。

(1) 加权平滑滤波

加权平滑滤波又称为一阶低通滤波,即每一个采样点的值通过上一个采样点的值与当前采样点的值取加权平均计算得到。加权平均可以实现有效阻断高频成分,保留低频信号,抑制周期性干扰,而且计算简便,易于实现。加权平均的计算公式为:

$$Value[i] = Value[i - 1] * (1 - \alpha) + Data[i] * \alpha. \quad (2.1)$$

其中 $Value$ 表示我们计算得到的输出数值, $Data$ 表示采集的传感器数值, α 表示加权系数,决定了过去数值与当前采样数值的重要程度,位于 0 到 1 之间,起到平滑的作用。

(2) 滑动平均滤波

滑动平均滤波就是使用过去一段时间连续采集的传感器数据,通过平均处理以后作为每个点的输出数值。这是一种常见的数字滤波方法,可以有效消除波动,降低随机噪声的干扰。同样它的计算复杂度较低,容易理解和实现,其计算公式为:

$$Value[i] = \frac{1}{W} \sum_{j=0}^{W-1} Data[i - j] \quad (2.2)$$

其中, $Value$ 为输出数值, $Data$ 为传感器原始采样数据, W 为选择的用于平均处理的窗口大小。在窗口移动过程中上述公式存在着重复计算问题,为了提高计算效率,充分利用之前的计算结果,可以通过推导递推公式改进计算方式,递推公式为:

$$Value[i] = Value[i - 1] + \frac{1}{W}(Data[i] - Data[i - W]) \quad (2.3)$$

2.2.2 数据分段

为从传感器数据流中识别人体当前的行为，有必要对连续的数据做分段处理获得行为数据实例。然后针对数据实例提取其中的部分特征进而才能通过分类算法识别出人体行为。所以分段的结果对识别结果会产生重要的影响，影响主要表现在识别准确率和识别实时性两方面。较长的数据段可以保证数据充分性提高识别准确率，而只有较短的数据段才可以保证一定的识别实时性，所以二者是一对矛盾体。为权衡二者的矛盾，重叠滑动窗口机制是在对连续数据流进行分段的常用方法。

使用滑动窗口机制对数据做分段处理需要确定两个重要的参数，首先是窗口大小，其次是重叠比例。研究者通过对比实验研究了窗口大小对识别结果的影响程度。当窗口长度低于一定程度，识别准确率会随着窗口长度减小有明显下降趋势。另外一方面，重叠的比例也会影响识别实时性。较高的重叠比例可以在满足数据充分性的同时提高实时性，但是在行为转变过程中，识别反应过程就会变长，因此重叠比例也是一个需要重点考虑的参数。目前基于可穿戴传感器和基于智能手机的行为识别研究中，大部分的窗口长度都选择在3到10s之间，而重叠比例多数会选择50%这样一个中间值。

2.3 特征提取与特征选择

特征提取与特征选择对于行为识别是极其重要的一环，特征集的好坏直接决定了分类结果中识别准确率的高低。好的特征应当比较准确地表征某一类行为的一方面特点，同时该特征在不同行为之间应当表现出一定的区分度。因此，在分类之前，需要从连续的传感器数据流中提取出一系列的特征，同时还需要从这一系列特征中选择一个最佳的特征集，用于分类算法对该行为实例进行分类。本小节将从特征提取和特征选择两个步骤介绍它们通常用到的技术方法。

2.3.1 特征提取

运动类型传感器所采集的关于人体行为的数据，通常都具有一定的波动性和周期性。因此基于传感器的行为识别，针对加速度等数据一般都会提取时域和频域特征，以及不同轴向数据的相关性，进而研究不同的行为特点。下面从时域和频域两个方面介绍常用特征。

(1) 时域特征

时域特征通过时域信号直接计算得到，计算简单，复杂度低。时域特征通常包括均值、均方根、方差、标准差、最值、相关系数等。

均值 (\bar{X}) 和均方根 (Root Mean Square, RMS) 描述了传感器数据在一个窗口时间内的平均大小, 代表传感器数据的直流分量, 体现了时域信号的低频特性。它们的计算公式如下:

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N x[i] \quad (2.4)$$

$$RMS(X) = \sqrt{\frac{1}{N} \sum_{i=1}^N x[i]^2} \quad (2.5)$$

方差 (σ_X^2) 和标准差 (σ_X) 描述了传感器数值分布的离散程度, 体现了运动传感器信号的稳定性, 方差计算公式如下, 标准差为方差的算术平方根。

$$\sigma_X^2 = \frac{1}{N-1} \sum_{i=1}^N (x[i] - \bar{X})^2 \quad (2.6)$$

其中, \bar{X} 表示 X 轴向上窗口时间内传感器数据的均值, N 为窗口时间内数据采样点数。

相关系数 (r_{XY}) 是一个常用统计量, 常用于衡量变量之间的线性相关程度。传感器的不同轴向的数据之间的相关系数可以很好地表征行为的运动模式, 可以用于区分不同的运动行为。 X 与 Y 轴的相关系数的计算公式如下:

$$r_{XY} = \frac{\sum_{i=1}^N (x[i] - \bar{X})(y[i] - \bar{Y})}{\sqrt{\sum_{i=1}^N (x[i] - \bar{X})^2} \sqrt{\sum_{i=1}^N (y[i] - \bar{Y})^2}} \quad (2.7)$$

其中, \bar{X} 和 \bar{Y} 分别表示 X , Y 轴向上窗口时间内传感器数据的均值, N 为窗口时间内数据采样点数。

此外时域特征还包括最大值、最小值、四分位距、分布直方图等, 这里不再一一介绍。

(2) 频域特征

频域特征可以表现运动行为的周期性特点, 通常需要先对时域信号做快速傅里叶变换 (Fast Fourier Transform, FFT), 然后再对频域信号计算频域特征值。频域的特征通常包括频域的最值、频谱能量、频域熵、功率谱密度等。

频谱能量 (*Energy*) 描述运动状态下, 传感器信号的周期特性, 其计算方式为对快速傅里叶变换后的频谱序列各个分量的幅度计算平方和, 其计算公式如下:

$$Energy(X) = \frac{\sum_{i=1}^N |F_i|^2}{N} \quad (2.8)$$

其中, $|F_i|$ 是信号频域信号的第 i 个分量的幅度。

2.3.2 特征选择

通过一系列的特征计算，可以组成关于一段窗口时间内数据的特征向量。如果特征向量中特征数量太多，一方面需要消耗大量的计算资源，另一方面还会在训练分类模型中造成过拟合导致人体行为识别准确率下降。因此我们需要从可选特征向量中选择最佳特征集用于训练分类模型以及行为实例的分类。特征选择方法很多，使用较为广泛的主要包括主成分分析法，线性判别分析法以及根据信息增益特征排序选择方法等。

主成分分析 (PCA)，就是通过正交变换，将原来存在一定相关性的特征向量变换为在分量上不相关的随机向量。具体地，首先计算特征向量的协方差矩阵而转换为一个对角矩阵，然后对其做正交变换，将其变换到 p 个正交方向，从而将多维的特征向量降为低维向量，而且尽可能多地保留信息，从而达到降维的效果。

线性判别分析法 (LDA)，其基本思想是将高维的特征向量映射到最优的矢量空间，然后抽取分类信息以及降低特征空间的维数。通过映射以后的特征空间具有最优的可分离性，在新的子空间中具有最小的类内距离和最大的类间距离。最终在降低特征维度以后获得最佳的分类效果。

另外一种常用的方法就是使用有监督的方法计算每一维特征的信息增益或信息增益比，进而对所有特征排序，然后选择信息增益或信息增益比最大的若干特征组成特征集。信息增益 (information gain, IG), 其计算公式如下：

$$Entropy(t) = - \sum_{i=1}^c p(i|t) \log_2 p(i|t) \quad (2.9)$$

$$IG = Entropy(parent) - \sum_{j=1}^k \frac{N(v_j)}{N} Entropy(v_j) \quad (2.10)$$

其中， $Entropy(\cdot)$ 表示信息熵， t 表示记录总数， c 表示类别总数， $p(i|t)$ 表示类型 i 记录数所占的比例；在公式 2.10 中， k 表示属性值的个数， N 表示记录总数， $N(v_j)$ 表示按照某特征分类，实例被分为 j 类的实例数量。因此信息增益其实就是按照某一个特征对所有实例分为 k 类，分类前后信息熵的差值。这种方法计算简单且易于理解，尽可能地保留了特征空间中不同类别行为之间的区分度，选择的特征集可以较好地用于分类模型。

2.4 分类算法

所谓人体行为识别就是根据一定时间的行为特征判断这段时间最有可能的行为，可以将其归结为分类问题。从数据挖掘和模式识别的角度看，行为识别就

是一个多分类的问题。在模式识别领域存在着诸多的成熟分类算法，本小节将从基础分类算法和提升分类算法两部分介绍常用于人体行为识别的分类算法。

2.4.1 基础分类算法

基础分类算法由于其算法简单易于实现，而且算法复杂度较低，因此需要在智能手机终端对行为作出识别判断的研究中，这类算法应用特别广泛。常用于基于智能手机的行为识别研究中的基础分类算法主要包括 K-近邻分类算法，朴素贝叶斯算法，决策树和支持向量机等。

- K-近邻分类算法 (K-Nearest Neighbor, KNN)

K-近邻分类算法是一种有监督的惰性机器学习算法。该算法简洁且易于理解，其基本思想就是在特征空间中定义一种实例之间的距离，使用最多的时欧氏距离，当有实例需要判定类别时，在所有实例中按照定义好的特征空间距离寻找 K 个与之距离最短的实例，根据这 K 个实例的标签决定该实例的类别。KNN 的算法的优点是简单易于实现，且不需要训练分类模型，但也有一定的缺点。使用 KNN 必须保存一定数量的实例，占用一定的存储空间，而且它是一种惰性分类算法，需要在识别时计算实例之间的距离，可能会对识别实时性造成一定影响。

- 朴素贝叶斯分类算法 (Naive Bayesian)

朴素贝叶斯分类算法是基于贝叶斯定理之上实现的有监督的学习算法，贝叶斯定理如下：

$$P(H|X) = \frac{P(X|H)P(H)}{P(X)} \quad (2.11)$$

其中， H 表示一种假设，在分类模型中表示分为某一类的假设， X 表示支持该假设的证据，在分类模型中表示特征向量的某一个特定取值组合， $P(X)$ 和 $P(H)$ 是 X 和 H 的先验概率， $P(X|H)$ 是在 H 条件下 X 的条件概率。

朴素贝叶斯分类算法的基本假设是所有特征彼此独立。因此条件概率可以同以下方法计算：

$$P(X|H) = \prod_{k=1}^n P(x_k|H) \quad (2.12)$$

其中， x_k 表示第 k 个属性的值。由于先验概率容易获得，而条件概率计算以后就可以计算获得一个特征组合下，每一个假设分类的后验概率，通过比较选择最大后验概率即可获得分类结果。朴素贝叶斯分类算法同样简单易于实现，但是最大的限制就在于对特征彼此独立的假设条件。

- 决策树 (Decision Tree)

决策树是一种有监督的学习分类算法，其分类的流程实例如图所示。决策树的每个叶节点代表一个类别，每个分支代表一个组属性值组合。决策树的建立时基于实例数据的信息熵。每一步的数据实例分裂都选择使得信息增益或信息增益比最大的特征将数据实例分裂为若干类，直到将所有实例都分类。为了避免出现过拟合，决策树中还可以通过剪枝的方法泛化模型。决策树最大的优势就是易于理解分类规则，易于实现，而且不依赖于特征的独立性，所以较为广泛地应用在行为识别当中。

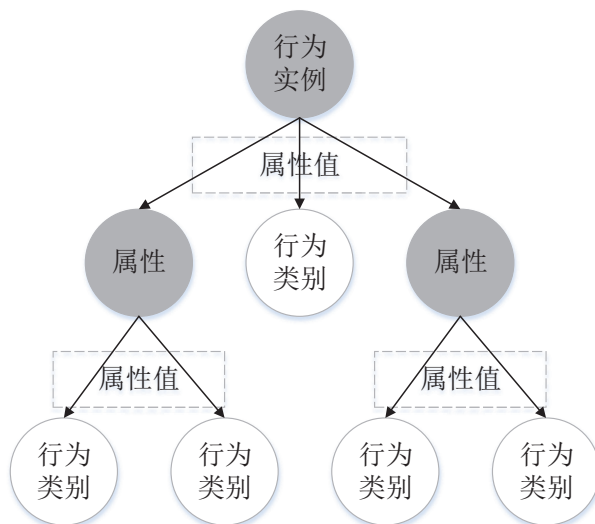


图 2.4 决策树分类算法流程图

- 支持向量机 (Support Vector Machine, SVM)

支持向量机是一种最为常用的有监督学习算法，它通过计算一个或多个高维的超平面将实例数据分割成多个类，其原则是使得超平面与支持向量的间隔最远。对于线性可分情况，可以直接计算超平面用于分类，对于线性不可分情况可以使用非线性映射算法将低维输入线性空间映射到高维的特征空间，使其线性可分，然后求解超平面对其进行分类。支持向量机同样广泛应用与行为识别，姿势识别等领域。

2.4.2 提升分类算法

由于智能手机的计算能力有限以及行为识别对实时性的要求，基于智能手机的行为识别研究中，提升的分类算法应用并不太广泛，这里只介绍随机森林分类算法。随机森林计算相对简单，复杂度相对较低，而且一些研究者也通过实验表明该学习方法在行为识别中取得了很好的效果。

- 随机森林分类算法 (Random Forest)

随机森林分类算法是决策树的一种组合形式。在随机森林的建立阶段,从 M 个特征中随机选择 m 个特征,其中 $m \ll M$,使用这 m 个特征建立决策树,其过程与独立决策树完全相同。多次执行相同过程,这些随机选择特征集的决策树就组建成了随机森林。在决策分类阶段,实例会通过每一棵决策树进行分类,最终的结果由所有决策树的分类结果投票决定。

随机森林在建立阶段一方面由于随机选择少量特征,不容易出现过拟合,而且训练速度较快,计算复杂度相对较低,另一方面是从特征集中随机选择特征,因此也可以用于高维特征数据实例的分类,而且对特征选择的要求不高。同时,在决策分类阶段,由于综合了多个决策树的结果,在准确率上有了很大的提高,在应用到行为识别上,这一点在文献中通过实验获得了证实。

2.5 本章小结

本章简要介绍了基于智能手机行为识别的相关技术。首先简要概述了智能手机中内置传感器种类和功能以及手机的数据采集模块。然后介绍了数据预处理方法,包括低通滤波和数据分段处理,同时介绍了行为识别中常用特征以及特征选择方法。最后介绍了可以用于基于传感行为识别的分类算法

第3章 基于智能手机的两层多策略行为识别框架

在人体行为识别的基础之上应用极为广泛的应用，它们可以给现代人的娱乐生活、医疗健康等诸多方面带来极大的便利与帮助。而对于此类应用，准确地感知和识别用户姿势或行为是其中最为关键的核心任务。为了感知和识别用户行为，首先需要比较方便并且具有较少用户侵入性地采集有关人体的行为数据，其次需要设备具有能力传输或者处理数据，进一步判断和识别用户行为。近些年随着智能手机的不断发展，仅仅通过智能手机这一个设备已经具备了上述条件。首先智能手机内部集成有多种传感器，可以很好地采集用户的运动信息，其次智能手机的应用越来越广泛，其与现代人的关系也愈加密切，因此它可以方便且无侵入性的长期监测用户的运动信息。最后智能手机的存储和计算能力不断增强，现在已经完全可以应对提取特征，运行分类算法等复杂计算，因此可以很好地完成识别任务，且避免了传感器数据通信的麻烦。

基于智能手机进行行为识别，不仅应用方便灵活，而且研究者也通过实验表明内置的多种类型传感器可以有效提高识别准确率。未来随着智能手机的不断进步和发展，基于智能手机的行为识别具有良好的应用前景。但是，智能手机在使用方便灵活的同时也存在着其他的问题。由于它的不固定，其位置和方向的变化会对内置传感器所采集的运动数据产生很大干扰，对最终的识别结果影响较大。因此我们需要提出新的解决方法降低这方面的影响。

为解决上述问题，本章提出一种基于智能手机的两层多策略行为识别方案框架，其流程框图如图所示，框架主要包括数据获取，分组算法和多策略分类三部分。首先多个传感器以固定的采样率采集关于人体的行为数据信息。同时为了可以实现实时地行为识别，本文采用带有重叠的滑动窗口机制对智能手机所采集的传感器数据分割为固定窗口时间长度的数据段，然后对于每一段数据提取若干行为特征组成特征向量。基于这一特征向量，根据不同的行为分类问题通过信息增益排序的方式选择最佳特征子集用于训练相应的分类器并使用该分类器完成最终的分类任务。在本文的框架中，行为分类由两层组成，首先在第一层中为分组模型，即根据行为之间的相似程度被分为若干组。然后在第二层中根据不同组的行为的不同特点使用不同策略和相应的最佳分类器进行最后的分类。

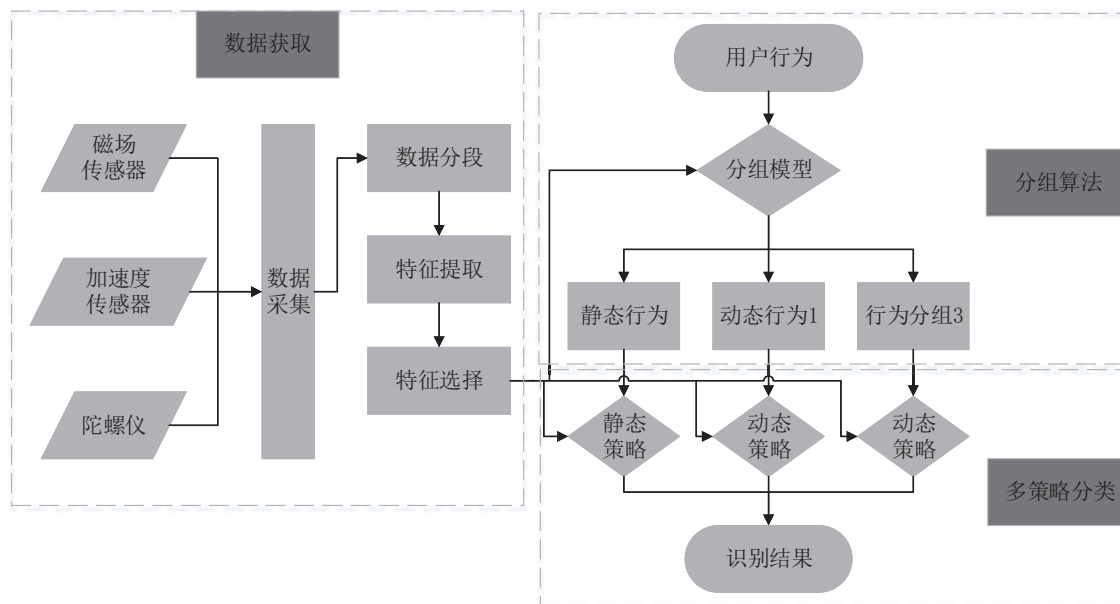


图 3.1 两层多策略的行为识别框架流程图

3.1 数据获取与处理

3.1.1 数据采集

在本文的框架中，数据集主要来自几乎所有智能手机内部都有集成的三类传感器，包括加速度传感器，陀螺仪和磁场传感器。每个传感器都以采样率采集数据并且采用长度为以及重叠为 50% 的滑动窗口对数据进行分割，最后每一段数据生成一个四维的信号向量 $(x, y, z, magnitude)$ ，基于数据向量就可以进行提取特征。其中：

$$magnitude = \sqrt{x^2 + y^2 + z^2} \quad (3.1)$$

3.1.2 特征提取

本文中所使用的全部特征列举在表格 1 中，主要包括时域的特征、频域的特征和关于自相关函数的特征。

表 3.1 本文用到的特征列表

| 类别 | 特征 | 符号 |
|------|------|------------------------|
| 时域特征 | 信号均值 | $\mu(\mathbf{x})$ |
| | 信号方差 | $\sigma^2(\mathbf{x})$ |
| | 窗口差值 | μT |
| | 窗口偏差 | μD |

下面以向量 \mathbf{x} 为例说明上述系列特征的细节，其中向量 \mathbf{x} 的长度为 N 。

- 时域特征

时域特征包括均值和方差等，计算简单并且可以有助于区分静止和动态行为，其中窗口差值和窗口偏差计算公式如下：

$$\mu T = \sum_{i=2}^M (|\mu_i - \mu_{i-1}|) \quad (3.2)$$

$$\mu D = \sum_{i=1}^M (|\mu_i - \mu|) \quad (3.3)$$

其中，窗口长度为 N 的向量 \mathbf{x} 被分割为 M 段， μ_i 表示第 i 段数据的均值， μ 表示向量 \mathbf{x} 的均值。

- 频域特征

本文中频域信号主要是通过快速傅里叶变换 (Fast Fourier Transform, FFT) 算法计算得到。在频域中，我们重点关注最大频域分量以及频域的能量值。频域特征与位置信息相关性较小，可以用来区分动态行为，而受到来自位置变化的影响较小。

- 自相关函数特征

信号的自相关函数可以通过公式计算得到。其中加速度数据和陀螺仪数据信号的自相关函数的图像分别如图 2 所示。

$$R_x[i] = \frac{1}{N} \sum_{j=i}^{N-1} x[j]x[j-i] \quad i = 0, 1, \dots, N-1 \quad (3.4)$$

如图 2 所示，传感器数据三维信号的自相关函数在同一点取得极值，我们记为 σ_i ，表示自相关函数的第 i 个极值。由于加速度传感器和陀螺仪是集成在同一部智能手机当中，因此他们所采取的数据计算相关函数极值的位置也相同。如果将它们各自的三维自相关函数加在一起就可以使得极值更加明显，不易被噪声混淆。另外使用自相关函数的和而非使用三轴向的传感器数据各自提取特征可以有效减少因为方向变化带来的影响。因此，在本文中关于自相关函数的特征都是使用自相关函数的和，即 $R = R_x + R_y + R_z$ ，而不是每一维数据的自相关函数。

使用自相函数的和计算以下特征，其中本文中使用前 m 个极值，计算公式如下：

$$R_M = \frac{1}{m} \sum_{i=1}^m R[\tau_i] \quad (3.5)$$

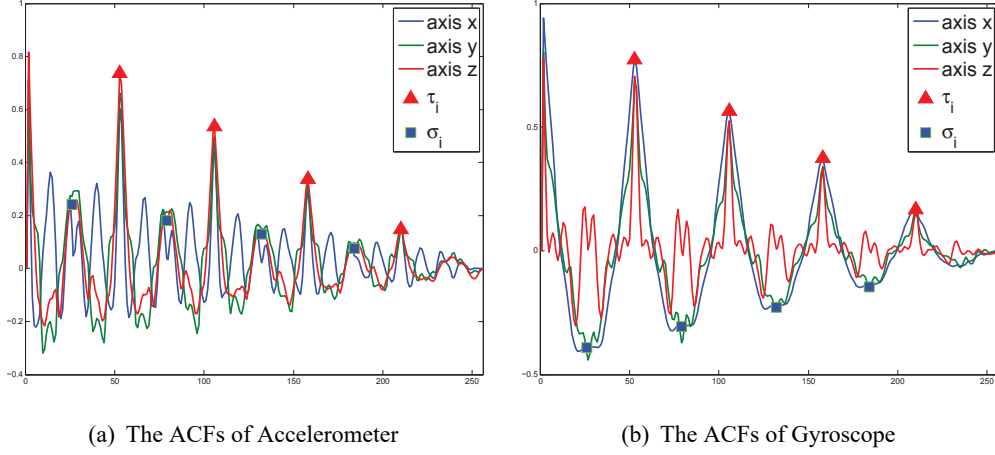


图 3.2 The ACFs of three-dimensional signals

$$P = \frac{1}{m} \sum_{i=1}^m (\tau_i - \tau_{i-1}) \quad (3.6)$$

$$Diff = \frac{1}{m} \sum_{i=1}^m \sum_{j=\tau_i-3}^{\tau_i+3} |R[j] - R[j-1]| \quad (3.7)$$

关于自相关函数的其他特征都与相邻极值中点 σ_i 处的函数值有关。在本文中，自相关函数相邻极值中点 σ_i 附近的一系列函数值被抽象为一个向量，比如 $\mathbf{r} = \frac{1}{m} \sum_{i=1}^m \{R[j]\}, j = \sigma_i - 3, \sigma_i - 2, \dots, \sigma_i + 3$ 。这一向量的最大值、最小值和平均值被作为本方案中最后三个特征，分别表示为 Mid_M, Mid_m, Mid_μ 。关于自相关函数的特征具有方向独立性的特点，因此可以有效区分动态行为而受到来自方向变化的影响较小。

在本方案中使用的三个传感器，时域和频域特征从四维数据中提起包括三轴方向和模值，即 $d = \sqrt{x^2 + y^2 + z^2}$ ，共组成 60 维特征向量。而自相关函数的特征则是提取自加速度传感器和陀螺仪的三轴方向的自相关数之和，即组成 12 维自相关函数特征集。因此最终的特征向量共有 72 维，然后对于不同的分类任务，分别计算这些特征的信息增益并排序，最终为不同的分类问题选择最佳特征集。通过为不同分类任务选择维数较小的特征数量，不但可以有效减少特征计算的复杂度，而且可以有效利用不同特征在不同分类问题中的优势。

3.2 分类模型

本文中的方案框架将分类模型分为两层，第一层为分组模型，主要负责将行为分类至某一组，组内的行为相似度高，不易区分，但是组间的区分度较大，易于分类，不易受到干扰因素的影响，误差率低。分类模型的第二层则是针对不同

组行为的特点，采用对应最佳策略对其进一步分类。在本文中，考虑静态和动态两类行为分类策略。由于静态行为在运动传感器数据中没有明显特征，因此本文考虑借助于识别过程中的过渡态行为进一步判断静态行为。而对于动态行为，容易受到来自位置变化的影响，本文方案中考虑使用位置分类器识别位置信息，然后在不同位置训练特定分类器对动态行为进一步分类。

3.2.1 分组模型

实际生活中一些行为之间的区分度十分明显，比如静止行为和跑步，即使存在位置和方向变化的干扰，也可以很容易的区分这些行为^[29]。因此在本文方案中，所有行为将根据行为之间的差异程度首先分为若干组，在识别过程中，所有行为可以利用第一层分类器判决他们属于哪一个组。行为的分组结果的获取是首先通过一个简单的分类方法对测试数据集进行分类，并根据行为的混淆矩阵计算行为之间的行为相似度。行为之间的相似度定义如下：

$$\omega_{ij} = \frac{c_{ij} + c_{ji}}{c_{ii} + c_{ij} + c_{ji} + c_{jj}} \quad (3.8)$$

其中， c_{ij} 表示在行为分类混淆矩阵中，行为 i 的实例被分类器分为行为 j 的数量。

然后所有的行为可以根据上述公式计算出的行为相似度进行分组，分组的结果应满足以下原则：

$$\begin{aligned} (1) & \bigcup_i A_{group-i} = A \\ (2) & A_{group-i} \cap A_{group-j} = \phi, i \neq j \\ (3) & \forall a \in A_{group-i}, \exists b \in A_{group-i} \wedge b \neq a, \omega_{ab} \geq \lambda_\omega \\ (4) & \forall a \in A_{group-i}, \forall b \in A_{group-j} \wedge i \neq j, \omega_{ab} \leq \lambda_\omega \end{aligned} \quad (3.9)$$

在本文中，行为集共包括六类不同行为，包括坐 (ST)，站 (SD)，行走 (WK)，跑步 (RN)，上楼 (AS) 和下楼 (DS)。本文所提出的框架并不局限在这六种行为，框架可以很好地扩展应用到其他行为。根据训练集数据，我们选择信息增益最大的前 10 个特征和决策树的分类方法对行为分类。这里相似度的阈值设置为 $\lambda_\omega = 0.05$ 。通过交叉验证的方法可以从识别结果中得到混淆矩阵，进而计算出不同行为之间的相似度，相似度的结果如图 3 所示。

根据相似度行为的分类结果如表格所示，此结果也刚好符合我们正常的思维习惯。

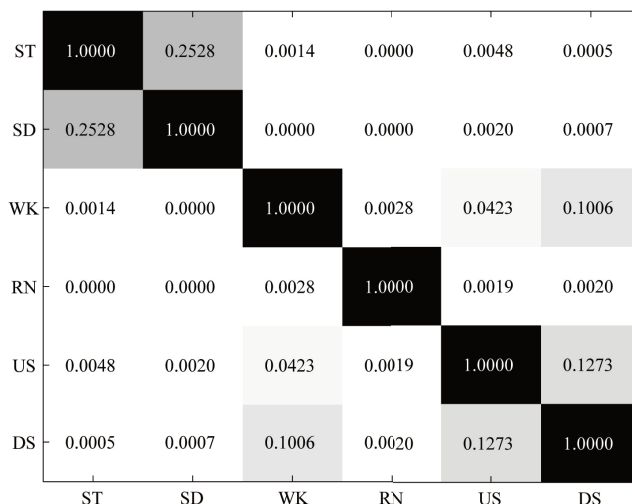


图 3.3 行为之间的相似度

表 3.2 The result of activity grouping

| Type | Activity |
|--------------|----------------------|
| Static | Sitting(ST) |
| | Standing(SD) |
| Slow Dynamic | Walking(WK) |
| | Ascending Stair(AS) |
| | Descending Stair(DS) |
| Fast Dynamic | Running(RN) |

3.2.2 静态行为分类策略

对于静态行为，比如坐和站的状态，它们的运动特征几乎没有区别，因此根据加速度等信息很难区分它们。另外，也不能像基于可穿戴传感器的行为识别中使用方向信息进行判断，因为手机并不是相对于人体是固定不变的。为此，在本文中我们提出一种间接的策略区分静态行为，即引入转换行为状态。例如，对于区分坐和站，转换状态，包括坐下和站起等，可以帮助区分两类静止行为。本文中区分静止行为的方法框架如图 4 所示。

如图 4 所示，如果前一次第一层分类的识别结果为静态行为且陀螺仪关于角速度的信号模值的最值没有超过之前设定的阈值，则此次保持上次的判决结果。否则，对前一个判决周期内的转换行为利用之前训练的分类器进行分类。根据这一分类器的分类结果，间接推断出静止的行为状态。

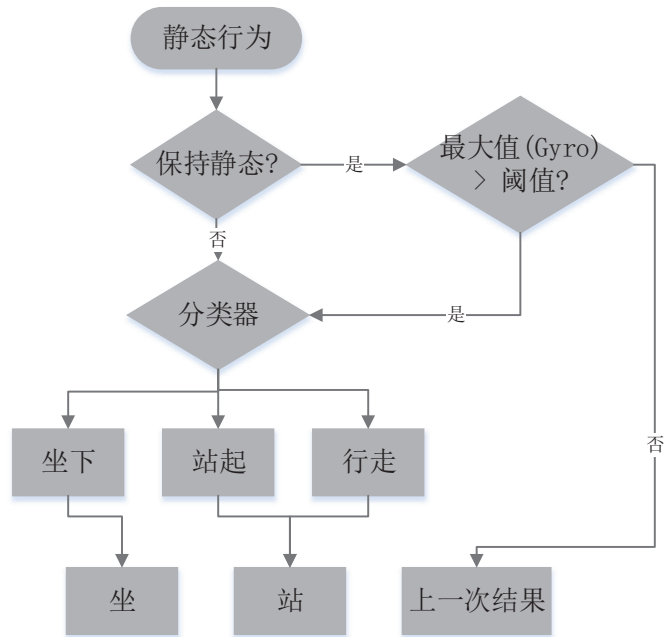


图 3.4 静态行为分类策略流程图

3.2.3 动态行为分类策略

对于动态的行为，运动传感器所采集的数据很容易受到位置和方向变化的影响，因为当手机处于人体不同位置时，加速度等信息会表现出不同的信号模式。因此分类器对动态行为的分类很容易受到手机所处位置和方向变化的影响，尤其是对于那些相似行为，即被分在同一组的行为。在本文中，我们提出一种位置辅助分类器的方法可以有效降低位置变化带来的影响。该方法的关键就是对于每一次判定为动态行为时，首先使用之前训练的位置分类器对其分类获取其位置信息。然后再针对不同位置，使用相应位置下所选取的最佳特征集以及所训练的分类器对其进行最终的行为分类。在本文中，在采集数据时智能手机分别被放置在四个不同位置，分别是手中，上衣口袋，裤子口袋，裤子背面口袋。在训练位置分类器时，上衣口袋被定义为上身位置，裤子口袋和裤子背部口袋被定义为下身位置。动态行为分类策略的过程如图 5 所示。引入位置辅助分类器不但可以有效降低位置变化带来的影响，而且还可以根据不同位置下运动传感器的不同特征选择各自最佳的特征集，进而训练各自最佳的分类器，可以有效改善最终的分类结果。




图 3.5 动态行为分类策略

3.3 分类实验结果

3.3.1 数据采集实验以及参数设定

在实验过程中，我们共有 6 人参与数据集的采集，而我们最初将所有传感器的采样率都设定为 50Hz 。我们所采集的数据集的时间分布如表格所示。所采集的数据会通过滑动窗口的方法对其进行分段，窗口的时间长度为 $T = 5\text{s}$ ，重叠率为 50%。对于每一个窗口内的数据可以提取我们前面所提到的一系列特征，然后分一个分类器都可以根据特征的信息增益选择最佳的特征集。在实验过程中，我们设定都选择信息增益最高的 10 个特征。

表 3.3 The data set distribution

| Time(minute) / Activity / Position | ST | SD | WK | RN | AS | DS |
|------------------------------------|----|----|----|----|----|----|
| | | | | | | |
| Hand | 12 | 12 | 30 | 30 | 30 | 30 |
| Coat Pocket | 12 | 12 | 30 | 30 | 30 | 30 |
| Trouser Pocket | 12 | 12 | 30 | 30 | 30 | 30 |
| Rear Pocket | 0 | 12 | 30 | 30 | 30 | 30 |

对于分类器的选择，我们统一都是用随机森林作为默认的分类算法，该算法在^[30]中，作者已经通过实验验证了其对行为识别的有效性。在计算每一层分类

器的分类结果时,我们采用选择其中五个参与者的数据作为训练集,剩余一个参与者的数据作为测试集,然后依次执行六次,计算这六次的平均值。在本文中,结果的评定指标包括正例正确率 (True Positive, TP), 误报率 (False Positive, FP), 准确率 (Precision), 召回率 (Recall), F 系数 (F-Measure) 等。

3.3.2 分类结果与分析

将所有行为分为三组以后,相应数据也合并为有三个类标签的数据,进而训练相应的随机森林分类器。在第一层使用该分类器对数据进行分组,其结果如表格 3 所示。由于根据之前的分组原则,不同组之间行为的差异很大,所以第一层的识别效果比较好。

表 3.4 the results in the first layer

| Classes | TP Rate | FP Rate | Precision | Recall | F-Measure |
|---------------|---------|---------|-----------|--------|-----------|
| Static | 0.997 | 0.001 | 0.997 | 0.997 | 0.997 |
| Slow Dynamic | 0.997 | 0.004 | 0.997 | 0.997 | 0.997 |
| Fast Dynamic | 0.993 | 0.001 | 0.992 | 0.993 | 0.993 |
| Weighted Avg. | 0.997 | 0.003 | 0.997 | 0.997 | 0.997 |

对于静态行为,本文仅以坐和站为例,因此实验过程中采集了坐下、站起以及从静止变为行走等过渡状态下的数据。实验参与者周期性地坐下、站起、行走等,周期时间长度设定为 15s。在这个过程中陀螺仪所采集的数据如图 10 所示。

传感器数据被分段,时间窗口长度依然为,但是不再有重叠。然后从这些时间窗口内的数据中提取相应特征并利用训练数据训练随机森林分类器。最后使用该分类器对过渡行为进行分类,分类结果如表格 4 所示。而通过过渡态的行为分类,根据我们之前所述的静态行为分类方法即可以间接获取静态的行为状态。

表 3.5 静态行为分类策略的分类结果

| Classes | TP Rate | FP Rate | Precision | Recall | F-Measure |
|--------------|---------|---------|-----------|--------|-----------|
| Sit-Stand | 0.9848 | 0.0014 | 0.9924 | 0.9848 | 0.9886 |
| Stand-Sit | 0.9924 | 0.0056 | 0.9704 | 0.9924 | 0.9813 |
| Walking | 0.9966 | 0 | 1.0000 | 0.9966 | 0.9983 |
| Weighted Avg | 0.9941 | 0.0011 | 0.9942 | 0.9941 | 0.9941 |

在实验过程中,我们同样计算了位置分类器的分类准确率,这对于位置辅助

的动态行为分类是十分重要的。如表格 5 所示, 位置分类器的分类准确率较高, 因此首先进行的位置分类对于行为分类结果的准确率影响并不大, 也就表明位置辅助的动态行为识别方法有其重要的意义。

表 3.6 动态行为分类策略的分类结果

| Classes | TP Rate | FP Rate | Precision | Recall | F-Measure |
|--------------|---------|---------|-----------|--------|-----------|
| Hand | 0.9927 | 0.0033 | 0.9937 | 0.9927 | 0.9932 |
| Upper Body | 0.9282 | 0.0163 | 0.9058 | 0.9282 | 0.9169 |
| Lower Body | 0.9720 | 0.0228 | 0.9782 | 0.9720 | 0.9751 |
| Weighted Avg | 0.9728 | 0.0152 | 0.9730 | 0.9728 | 0.9729 |

最后, 我们通过对本文提出的两层多策略的分类框架与之前两篇文献^{[14],[31]}所提出的方法做比较, 对分类结果做出分析。为了与之前两篇文献的实验设定一直, 本文的行为集中坐和站合并为一类, 成为静止状态 (SC)。最后的识别结果分别如表格 6, 7, 8 所示。

表 3.7 本文框架的分类结果

| Classes | TP Rate | FP Rate | Precision | Recall | F-Measure |
|--------------|---------|---------|-----------|--------|-----------|
| SC | 0.9972 | 0.0010 | 0.9976 | 0.9972 | 0.9974 |
| WK | 0.9974 | 0.0201 | 0.9384 | 0.9974 | 0.9575 |
| RN | 0.9938 | 0.0013 | 0.9925 | 0.9938 | 0.9934 |
| AS | 0.8926 | 0.0193 | 0.8737 | 0.8926 | 0.8830 |
| DS | 0.8654 | 0.0132 | 0.9312 | 0.8654 | 0.8971 |
| Weighted Avg | 0.9570 | 0.0095 | 0.9571 | 0.9570 | 0.9567 |

表 3.8 文献的分类结果

| Classes | TP Rate | FP Rate | Precision | Recall | F-Measure |
|--------------|---------|---------|-----------|--------|-----------|
| SC | 0.9988 | 0 | 1.0000 | 0.9988 | 0.9994 |
| WK | 0.8894 | 0.0245 | 0.9050 | 0.8894 | 0.8971 |
| RN | 0.9935 | 0.0003 | 0.9978 | 0.9935 | 0.9957 |
| AS | 0.7991 | 0.0541 | 0.7934 | 0.7991 | 0.7963 |
| DS | 0.8517 | 0.0420 | 0.8395 | 0.8517 | 0.8456 |
| Weighted Avg | 0.9039 | 0.0249 | 0.9044 | 0.9039 | 0.9041 |

表 3.9 文献的分类结果

| Classes | TP Rate | FP Rate | Precision | Recall | F-Measure |
|--------------|---------|---------|-----------|--------|-----------|
| SC | 0.9776 | 0.0012 | 0.9965 | 0.9776 | 0.9869 |
| WK | 0.7714 | 0.0758 | 0.7319 | 0.7714 | 0.7511 |
| RN | 0.9946 | 0.0011 | 0.9935 | 0.9946 | 0.9941 |
| AS | 0.7456 | 0.0489 | 0.7894 | 0.7456 | 0.7669 |
| DS | 0.7342 | 0.0659 | 0.7171 | 0.7342 | 0.7256 |
| Weighted Avg | 0.8455 | 0.0384 | 0.8475 | 0.8455 | 0.8462 |

参考文献

- [1] LARA O D, LABRADOR M A. A survey on human activity recognition using wearable sensors[J]. Communications Surveys & Tutorials, IEEE, 2013, 15(3): 1192–1209.
- [2] POPPE R. A survey on vision-based human action recognition[J]. Image and vision computing, 2010, 28(6): 976–990.
- [3] CHEN L, HOEY J, NUGENT C D, et al. Sensor-based activity recognition[J]. Systems, man, and cybernetics, Part C: Applications and reviews, IEEE Transactions on, 2012, 42(6): 790–808.
- [4] SU X, TONG H, JI P. Activity recognition with smartphone sensors[J]. Tsinghua Science and Technology, 2014, 19(3): 235–249.
- [5] ZHANG M, SAWCHUK A A. USC-HAD: a daily activity dataset for ubiquitous activity recognition using wearable sensors[C] // Proceedings of the 2012 ACM Conference on Ubiquitous Computing. 2012: 1036–1043.
- [6] YANG C-C, HSU Y-L. A review of accelerometry-based wearable motion detectors for physical activity monitoring[J]. Sensors, 2010, 10(8): 7772–7788.
- [7] ATALLAH L, YANG G-Z. The use of pervasive sensing for behaviour profiling—a survey[J]. Pervasive and Mobile Computing, 2009, 5(5): 447–464.
- [8] LANE N D, MILUZZO E, LU H, et al. A survey of mobile phone sensing[J]. Communications Magazine, IEEE, 2010, 48(9): 140–150.
- [9] SHOAIB M, SCHOLTEN H, HAVINGA P J. Towards physical activity recognition using smartphone sensors[C] // Ubiquitous Intelligence and Computing, 2013 IEEE 10th International Conference on and 10th International Conference on Autonomic and Trusted Computing (UIC/ATC). 2013: 80–87.
- [10] HUNG W-C, SHEN F, WU Y-L, et al. Activity Recognition with sensors on mobile devices[C] // Machine Learning and Cybernetics (ICMLC), 2014 International Conference on: Vol 2. 2014: 449–454.
- [11] VIET V Q, THANG H M, CHOI D. Adaptive energy-saving strategy for activity recognition on mobile phone[C] // Signal Processing and Information Technology (ISSPIT), 2012 IEEE International Symposium on. 2012: 000095–000100.
- [12] HENPRASERTTAE A, THIEMJARUS S, MARUKATAT S. Accurate activity recognition using a mobile phone regardless of device orientation and location[C] // Body Sensor Networks (BSN), 2011 International Conference on. 2011: 41–46.

- [13] RASHEED M B, JAVAID N, ALI ALGHAMDI T, et al. Evaluation of Human Activity Recognition and Fall Detection Using Android Phone[C] // Advanced Information Networking and Applications (AINA), 2015 IEEE 29th International Conference on. 2015 : 163 – 170.
- [14] ANJUM A, ILYAS M U. Activity recognition using smartphone sensors[C] // Consumer Communications and Networking Conference (CCNC), 2013 IEEE. 2013 : 914 – 919.
- [15] THIEMJARUS S, HENPRASERTTAE A, MARUKATAT S. A study on instance-based learning with reduced training prototypes for device-context-independent activity recognition on a mobile phone[C] // Body Sensor Networks (BSN), 2013 IEEE International Conference on. 2013 : 1 – 6.
- [16] WANG C, ZHANG J, WANG Z, et al. Position-independent activity recognition model for smartphone based on frequency domain algorithm[C] // Computer Science and Network Technology (ICCSNT), 2013 3rd International Conference on. 2013 : 396 – 399.
- [17] KELLY D, CAULFIELD B. An investigation into non-invasive physical activity recognition using smartphones[C] // Engineering in Medicine and Biology Society (EMBC), 2012 Annual International Conference of the IEEE. 2012 : 3340 – 3343.
- [18] YURUR O, LABRADOR M, MORENO W. Adaptive and energy efficient context representation framework in mobile sensing[J]. Mobile Computing, IEEE Transactions on, 2014, 13(8) : 1681 – 1693.
- [19] XIE F, SONG A, CIESIELSKI V. Activity recognition by smartphone based multi-channel sensors with genetic programming[C] // Evolutionary Computation (CEC), 2013 IEEE Congress on. 2013 : 1162 – 1169.
- [20] THIEMJARUS S. A device-orientation independent method for activity recognition[C] // Body Sensor Networks (BSN), 2010 International Conference on. 2010 : 19 – 23.
- [21] ZHAO K, DU J, LI C, et al. Healthy: A diary system based on activity recognition using smartphone[C] // Mobile Ad-Hoc and Sensor Systems (MASS), 2013 IEEE 10th International Conference on. 2013 : 290 – 294.
- [22] EL HALABI A, ARTAIL H. Integrating pressure and accelerometer sensing for improved activity recognition on smartphones[C] // Communications and Information Technology (IC-CIT), 2013 Third International Conference on. 2013 : 121 – 125.
- [23] DAS R D, RONALD N, WINTER S. Clustering based transfer detection with fuzzy activity recognition from smart-phone GPS trajectories[C] // Intelligent Transportation Systems (ITSC), 2014 IEEE 17th International Conference on. 2014 : 3138 – 3143.
- [24] YAN Z, SUBBARAJU V, CHAKRABORTY D, et al. Energy-efficient continuous activity recognition on mobile phones: An activity-adaptive approach[C] // Wearable Computers (ISWC), 2012 16th International Symposium on. 2012 : 17 – 24.

-
- [25] WANG Y, LIN J, ANNAVARAM M, et al. A framework of energy efficient mobile sensing for automatic user state recognition[C] // Proceedings of the 7th international conference on Mobile systems, applications, and services. 2009 : 179 – 192.
- [26] GORDON D, CZERNY J, MIYAKI T, et al. Energy-efficient activity recognition using prediction[C] // Wearable Computers (ISWC), 2012 16th International Symposium on. 2012 : 29 – 36.
- [27] VIET N H, MUNTKE-KAAS E, PLAGEMANN T. Quality and energy aware data acquisition for activity and locomotion recognition[C] // Pervasive Computing and Communications Workshops (PERCOM Workshops), 2013 IEEE International Conference on. 2013 : 493 – 498.
- [28] YURUR O, LIU C H, PERERA C, et al. Energy-efficient and context-aware smartphone sensor employment[J]. Vehicular Technology, IEEE Transactions on, 2015, 64(9) : 4230 – 4244.
- [29] LU H, YANG J, LIU Z, et al. The Jigsaw continuous sensing engine for mobile phone applications[C] // Proceedings of the 8th ACM Conference on Embedded Networked Sensor Systems. 2010 : 71 – 84.
- [30] bin ABDULLAH M F A, NEGARA A F P, SAYEED M S, et al. Classification algorithms in human activity recognition using smartphones[J]. International Journal of Computer and Information Engineering, 2012, 6 : 77 – 84.
- [31] BISIO I, LAVAGETTO F, MARCHESE M, et al. Comparison of situation awareness algorithms for remote health monitoring with smartphones[C] // Global Communications Conference (GLOBECOM), 2014 IEEE. 2014 : 2454 – 2459.

